

PCA

(Principal Component Analysis)


André Tavares da Silva
andre.silva@udesc.br

Objetivos

- Introduzir os conceitos de PCA
- Revisão dos conceitos básicos de estatística e álgebra linear.
- Definições e interpretação geométrica
- Como calcular (tutorial)
- Aplicações no reconhecimento de padrões

PCA

- Diferença entre PCA e LDA quando aplicados sobre os mesmos dados



Análise de Componentes Principais (PCA)

- Dado um conjunto D com n instâncias e p atributos (x_1, x_2, \dots, x_p) , uma transformação linear (ex.: rotação) para um novo conjunto de atributos z_1, z_2, \dots, z_p pode ser calculada como:

$$z_1 = a_{11} x_1 + a_{21} x_2 + \dots + a_{p1} x_p$$

$$z_2 = a_{12} x_1 + a_{22} x_2 + \dots + a_{p2} x_p$$

...

$$z_p = a_{1p} x_1 + a_{2p} x_2 + \dots + a_{pp} x_p$$

- Componentes Principais (PCs) são tipos específicos de combinações lineares que são escolhidas de tal modo que z_p (PCs) tenham as seguintes características

PCA: Características

- As p componentes principais (PC) são não-correlacionadas (independentes)
- As PCs são ordenadas de acordo com quantidade da variância dos dados originais que elas contêm (ordem decrescente)
 - A primeira PC representa a maior variabilidade do conjunto de dados original
 - A segunda PC define a próxima maior e assim por diante
 - Em geral, apenas algumas das primeiras PCs são responsáveis pela maior parte da variabilidade do conjunto de dados
 - O restante das PCs tem uma contribuição insignificante
- PCA é usada em Aprendizado de Máquina principalmente para a redução de dimensionalidade

PCA: Cálculo

- PCA pode ser reduzida ao problema de encontrar os autovalores e autovetores da matriz de covariância (ou correlação) do conjunto de dados
- A proporção da variância do conjunto de dados originais explicada pela i -ésima PC é igual ao i -ésimo auto-valor dividido pela soma de todos os p auto-valores
- Ou seja, as PCs são ordenadas decrescentemente de acordo com os autovalores
- Quando os valores dos diferentes atributos estão em diferentes escalas, é preferível usar a matriz de correlação em lugar da matriz de covariância

Estatística

- Variância

- Variância de uma variável aleatória é uma medida de dispersão estatística, indicando quão longe em geral os seus valores se encontram do valor esperado.

$$s^2 = \frac{1}{n - 1} \sum_{i=1}^n (x_i - \bar{x})^2,$$

- Desvio padrão é a raiz da variância

Estatística

- Covariância

- Variância é uma medida unidimensional, calculada de maneira independente pois não leva em consideração as outras dimensões.
- Covariância por sua vez, é uma medida bidimensional. Verifica a dispersão, mas levando em consideração duas variáveis aleatórias.


$$cov(X, Y) = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{(n - 1)}$$

Estatística

- Matriz de covariância
 - Para 3 variáveis aleatórias, x , y e z , o cálculo de todas as covariâncias (x - y , x - z e y - z) pode ser acomodada em uma matriz, a qual denomina-se matriz de covariância.

$$C = \begin{pmatrix} cov(x, x) & cov(x, y) & cov(x, z) \\ cov(y, x) & cov(y, y) & cov(y, z) \\ cov(z, x) & cov(z, y) & cov(z, z) \end{pmatrix}$$

$$Cov(x, y) = cov(y, x)$$


$$Cov(z, z) = var(z)$$

Álgebra

- Autovetores

- Como sabe-se duas matrizes podem ser multiplicadas se elas possuem tamanhos compatíveis. Autovetores são casos especiais neste contexto.

$$\begin{pmatrix} 2 & 3 \\ 2 & 1 \end{pmatrix} \times \begin{pmatrix} 1 \\ 3 \end{pmatrix} = \begin{pmatrix} 11 \\ 5 \end{pmatrix}$$

$$\begin{pmatrix} 2 & 3 \\ 2 & 1 \end{pmatrix} \times \begin{pmatrix} 3 \\ 2 \end{pmatrix} = \begin{pmatrix} 12 \\ 8 \end{pmatrix} = 4 \times \begin{pmatrix} 3 \\ 2 \end{pmatrix} \rightarrow \text{Múltiplo do vetor resultante}$$

Autovetores

- Nesse caso $(3,2)$ representa um vetor que aponta da origem $(0,0)$ para o ponto $(3,2)$.
- A matriz quadrada, pode ser vista como uma matriz de transformação.
- Se esta matriz for multiplicada por outro vetor, a resposta será outro vetor transformado da sua posição original.
- É da natureza desta transformação que surgem os autovetores.

Autovetores

- Propriedades
 - Podem ser achados somente em matrizes quadradas.
 - Para uma dada $n \times n$ matriz, existem n autovetores.
 - Nem todas as matrizes possuem autovetores.
 - Se o vetor for multiplicado por uma constante, ainda obteremos o mesmo resultado

$$2 \times \begin{pmatrix} 3 \\ 2 \end{pmatrix} = \begin{pmatrix} 6 \\ 4 \end{pmatrix}$$


$$\begin{pmatrix} 2 & 3 \\ 2 & 1 \end{pmatrix} \times \begin{pmatrix} 6 \\ 4 \end{pmatrix} = \begin{pmatrix} 24 \\ 16 \end{pmatrix} = 4 \times \begin{pmatrix} 6 \\ 4 \end{pmatrix}$$

Apenas fazemos o vetor mais longo, mas não mudamos a direção.

Autovetores/Autovalores

- Todos os autovetores são ortogonais (perpendiculares), ou seja os dados podem ser expressos em termos destes vetores.
- O valor pelo qual o vetor é multiplicado é conhecido como autovalor
 - Um autovetor sempre possui um autovalor associado.

Interpretação Geométrica



u é autovetor de T
 v não é autovetor de T

Definições

- Seja A uma matriz de ordem $n \times n$
- O número λ é o **autovalor** (*eigenvalue*) de A se existe um vetor não-zero v tal que

$$A v = \lambda v$$

- Neste caso, o vetor v é chamado de **autovetor** (*eigenvector*) de A correspondente à λ .

Calculando Autovalores e Autovetores

- Pode-se reescrever a condição:

$$A \mathbf{v} = \lambda \mathbf{v}$$

como

$$(A - \lambda I) \mathbf{v} = \mathbf{0}$$

onde I é a matriz identidade de ordem $n \times n$.

- Para que um vetor não-zero \mathbf{v} satisfaça a equação, $(A - \lambda I)$ deve ser **não** inversível.

Calculando

Autovalores e Autovetores

- Caso contrário, se $(A - \lambda I)$ tiver uma inversa, então

$$(A - \lambda I)^{-1} (A - \lambda I) v = (A - \lambda I)^{-1} 0$$
$$v = 0$$

- Mas, procura-se por um vetor v não-zero.

Calculando

Autovalores e Autovetores

- Voltando, isto é, o determinante de $(A - \lambda I)$ deve ser igual à 0.
- Chama-se

$$p(\lambda) = \det (A - \lambda I)$$

de **polinômio característico** de A .

- Os autovalores de A são as raízes do polinômio característico de A .

Calculando Autovalores e Autovetores

- Para se calcular o i -ésimo autovetor

$$\mathbf{v}_i = [v_1 ; v_2 ; \dots ; v_n]$$

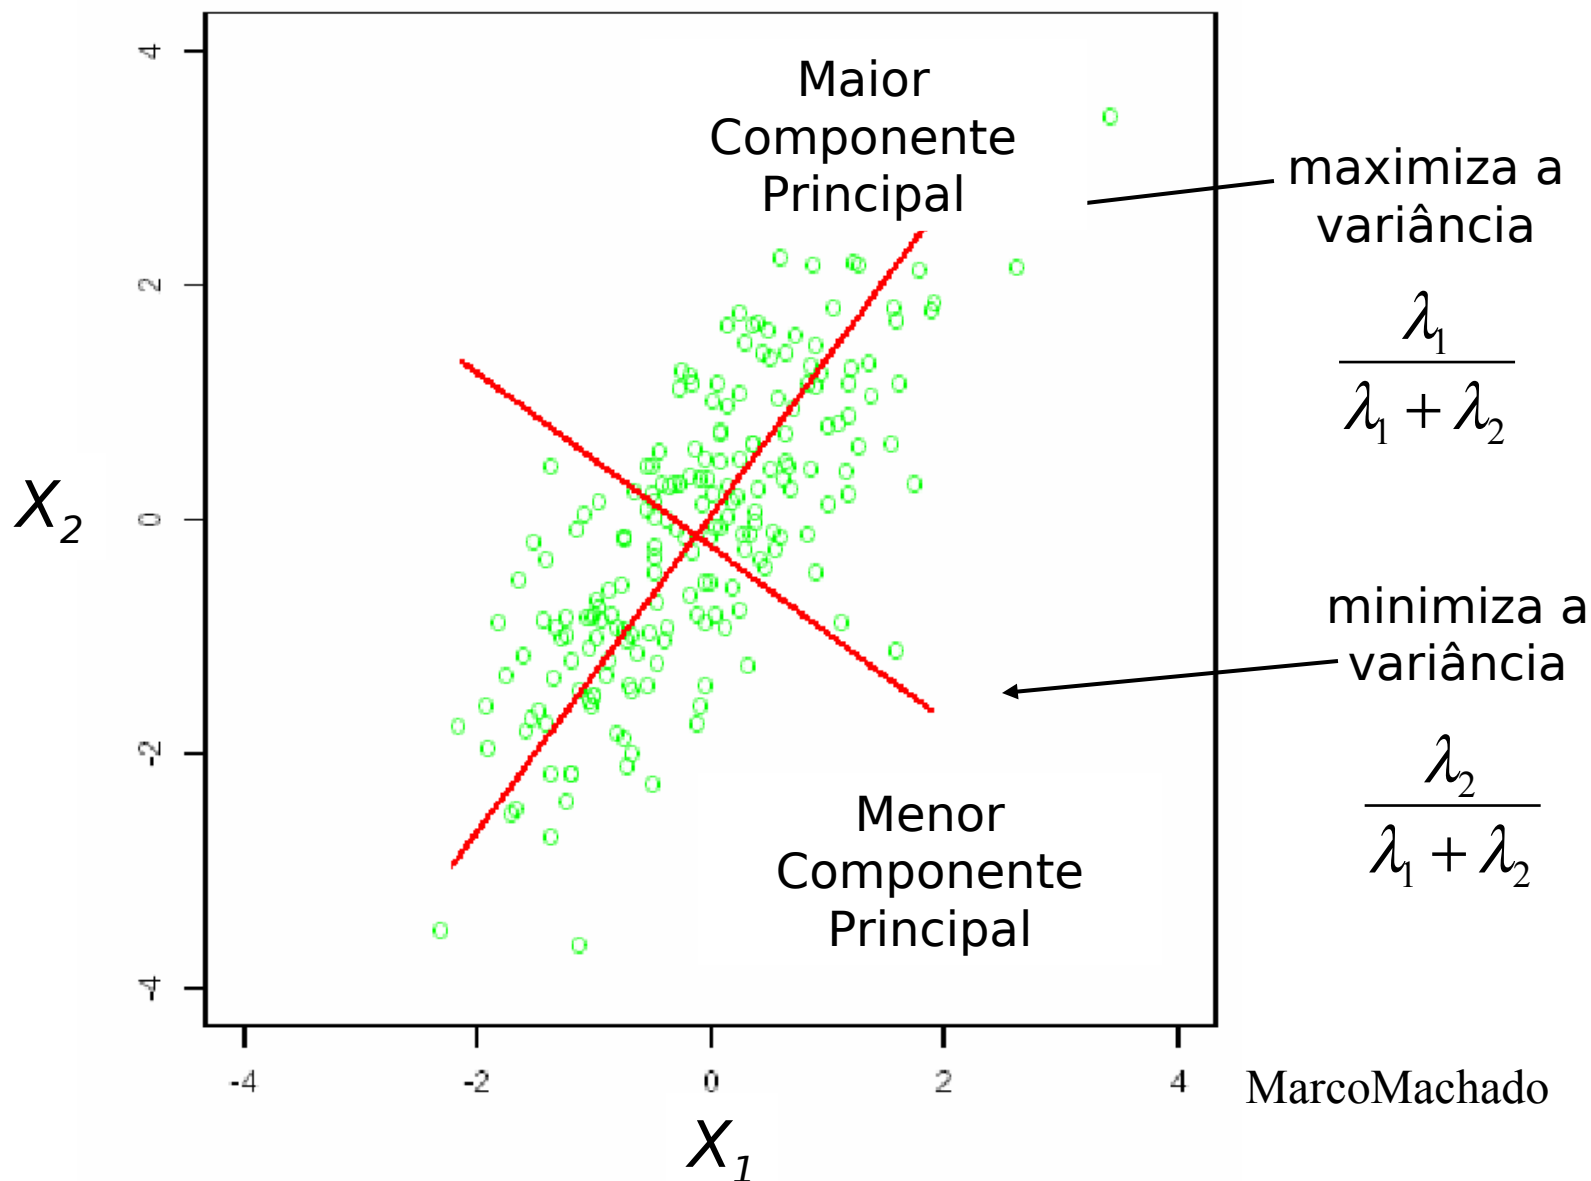
correspondente à um autovalor λ_i , basta resolver o sistema linear de equações dado por

$$(A - \lambda I) \mathbf{v} = 0$$

Análise dos Componentes Principais (PCA)

- Uma maneira de identificar padrões em dados, colocando em evidência suas similaridades e diferenças.
- Ferramenta importante para altas dimensões, onde não podemos fazer uma análise visual.
- Uma vez encontrados esses padrões, podemos comprimir os dados sem grande perda de qualidade.
- Escolha de características (representação)


PCA



Interpretação geométrica

$$J = \mathbf{x}^t \mathbf{S} \mathbf{x} \geq 0, \quad \mathbf{S} \text{ simétrica}$$

$$J = [u \quad v] [R] \begin{bmatrix} \lambda_1 & 0 \\ 0 & \lambda_2 \end{bmatrix} [R]^T \begin{bmatrix} u \\ v \end{bmatrix} = [u' \quad v'] \begin{bmatrix} \lambda_1 & 0 \\ 0 & \lambda_2 \end{bmatrix} \begin{bmatrix} u' \\ v' \end{bmatrix} = \text{const}$$



λ_1, λ_2 – autovalores de \mathbf{S}

$$\lambda_1 (u')^2 + \lambda_2 (v')^2 = \text{const}$$

PCA

- Variância total = soma das variâncias
- Variância total = traço de S

$$\text{tr}(S) = \sum_{i=1}^N \sigma_i^2 = \sum_{i=1}^N \lambda_i$$

- Eixos principais também representam a variância total do conjunto de dados.
 - Primeiro eixo: $\lambda_1/\text{traço}(S)$
 - Segundo eixo: $\lambda_2/\text{traço}(S)$


PCA Tutorial

- 1) Escolha um conjunto de dados.
- 2) Centralize os dados, subtraindo-os da média.

Dados	x	y
	2.5	2.4
	0.5	0.7
	2.2	2.9
	1.9	2.2
	3.1	3.0
	2.3	2.7
	2	1.6
	1	1.1
	1.5	1.6
	1.1	0.9

Dados Centrados	x	y
	.69	.49
	-1.31	-1.21
	.39	.99
	.09	.29
	1.29	1.09
	.49	.79
	.19	-.31
	-.81	-.81
	-.31	-.31
	-.71	-1.01

PCA Tutorial



PCA Tutorial

3) Calcule a matriz de covariância para os dados normalizados. Uma vez que os dados possuem duas dimensões, teremos uma matriz 2x2

$$cov = \begin{pmatrix} .616555556 & .615444444 \\ .615444444 & .716555556 \end{pmatrix}$$

PCA Tutorial

4) Encontre os autovetores e autovalores para a matriz de covariância.


- Uma vez que a matriz de covariância é quadrada podemos encontrar os autovetores e autovalores.

$$eigenvalues = \begin{pmatrix} .0490833989 \\ 1.28402771 \end{pmatrix}$$

$$eigenvectors = \begin{pmatrix} -.735178656 & -.677873399 \\ .677873399 & -.735178656 \end{pmatrix}$$

O que esses valores significam ??

PCA Tutorial



PCA Tutorial

5) Escolhendo os componentes que vão formar o vetor

- Como vimos, os autovalores são bastante diferentes.
- Isso permite ordenar os autovetores por ordem de importância.
- Se quisermos eliminar um componente, devemos então eliminar os que tem menos importância.

$$FeatureVector = (eig_1 \ eig_2 \ eig_3 \ \ eig_n)$$

PCA Tutorial

- No nosso exemplo temos duas escolhas
 - Manter os dois.
 - Eliminar um autovetor, diminuindo assim a dimensionalidade dos dados.
 - Maldição da dimensionalidade: quanto maior a dimensionalidade do seu vetor, mais dados serão necessários para a aprendizagem do modelo.

PCA Tutorial


5) Construindo novos dados.

- Uma vez escolhidos os componentes (autovetores), nós simplesmente multiplicamos os dados pelo autovetor(es) escolhidos.
- O que temos?
 - Dados transformados de maneira que expressam os padrões entre eles.
 - Os PCs (*Principal Components*) são combinações lineares de todas as características, produzindo assim novas características não correlacionadas.

PCA Tutorial

Dados transformados
usando 2 autovetores


x	y
-0.827970186	-0.175115307
1.77758033	.142857227
-0.992197494	.384374989
-0.274210416	.130417207
-1.67580142	-.209498461
-.912949103	.175282444
.0991094375	-.349824698
1.14457216	.0464172582
.438046137	.0177646297
1.22382056	-.162675287



PCA Tutorial

- Exemplo

$$y = \frac{-W_1 \times x - b}{W_2}$$



AUTOVETORES

-0.6779 -0.7352

-0.7352 0.6779

AUTOVALORES


1.2840

0.0491

Utilização do PCA

- Objetivo: reduzir a dimensionalidade do espaço de entrada R^n , mantendo tanta informação quanto possível, em um novo espaço R^n .
 - Adquirir os dados: Número de vetores...
 - Calcular a Matriz de Covariância/Correlação
 - Calcular os Autovalores e Autovetores
 - Escolher os autovetores: Critério da informação...
 - Mapear os dados para o novo espaço

Exemplo: Reconhecimento de Face



EigenFaces

Próxima aula!

Análise de Componentes Principais

- Principais Limitações
 - Assume apenas relações lineares entre os atributos
 - A interpretação dos resultados em termos dos atributos originais pode ficar mais difícil